

HIGP: Hindsight Inverse-Guided Planning in JEPA Latent Space

一句话：在 JEPA latent 空间里做 goal-conditioned 视觉规划。Inverse 模型用 hindsight 训成 strong proposal，forward 验证，MPC 微调。

核心：inverse proposes, forward verifies, MPC refines, environment executes.

1. 我们针对的痛点

现有 JEPA + CEM 类方法（LeWM, PLDM, DINO-WM）有三个系统性病根：

问题	现状
P1 Action OOD	CEM 随机采样 → 候选动作不在训练分布内 → forward verify 也救不回来
P2 Latent L2 不接地气	用 $\ \hat{z}_H - z_g\ $ 做 cost，latent 距离和真实"还差几步"相关性差
P3 长 horizon 复合误差	CEM 整条序列开环执行，forward 误差累积，长任务直接崩

GCBC 类方法（HILP, QRL）则反过来：完全 reactive，没有 horizon awareness，长任务也失败。

2. 我们的创新

创新 1：用 hindsight 把 inverse 训成 robust proposal

```
对每条 trajectory  $\tau = (z_0, a_0, \dots, z_T)$ :
  for each 起点  $i$ :
     $k \sim \text{Uniform}[1, T-i]$                                  $\leftarrow$  关键: 随机距离
     $z_g^{(i)} = z_{\{i+k\}}$                                      $\leftarrow$  hindsight 未来 goal
     $L_{\text{inv}} += ||h(z_i, z_g^{(i)}) - a_i||_1$ 
                                 $\uparrow$ 
                                监督 inverse 输出  $i \rightarrow i+1$  的真实首步动作
```

为什么"随机 k "是关键:

选择	后果
固定 $k = 1$ (GCBC 经典做法)	推理时 goal 远了直接 OOD
固定 $k = T$	近距离 OOD
随机 $k \sim U[1, T - i]$	各距离都见过, 推理时 robust

→ inverse 不再是 reactive GCBC, 是各 horizon 都 robust 的 **proposal model**。

创新 2: Inverse-guided warm-start MPC

替代 CEM 的随机全局搜索:

```
Step 1: warm-start       $A^0 = (h(z_t, z_g), h(\hat{z}_1, z_g), \dots, h(\hat{z}_{H-1}, z_g))$ 
Step 2: forward verify   $\hat{Z} = \text{imagine\_rollout}(z_t, A^0)$ 
Step 3: local refine     $A^* = \text{random\_search}(A^0, \sigma=0.1, M=64 \text{ candidates})$ 
Step 4: execute          $A^*[0]$ , 重观测, replan
```

直接对应三个病根的解药:

病根	解药
P1 Action OOD	Warm-start 来自 inverse → 完全在训练分布内
P2 Latent cost 不准	$\text{Cost} = \alpha J_{\text{goal}} + \gamma J_{\text{smooth}} + \eta J_{\text{prior}}$, 不再盲信 latent L2
P3 Long horizon	Receding-horizon replanning + 闭环重观测修正累积误差

创新 3：端到端联合训练

Encoder + Forward + Inverse 三件一起训：

$$\mathcal{L} = \mathcal{L}_{\text{jepa}} + \lambda_{\text{inv}} \mathcal{L}_{\text{inv}} + \lambda_{\text{cyc}} \mathcal{L}_{\text{cycle}}$$

而非 DINO-WM 那种 frozen encoder + 后接 dynamics 的两阶段。Cycle loss 是辅助： $f(z_t, h(z_t, z_g))$ 应回到 z_{t+1} ，让 f 和 h 互相校准。

3. 与现有工作的位置

方向	代表	HIGP 的差异
End-to-end JEPA	LeWM, PLDM, V-JEPA-2	加 inverse + 改推理范式
Frozen encoder + dynamics	DINO-WM	端到端训
Forward + Inverse joint	DeFI（分阶段）, JIF (VLA)	专为 planning ，不是 VLA
Quasi-metric / successor	HILP, QRL	隐式几何耦合，不显式构造 metric
Latent MPC	TD-MPC2	Inverse warm-start 替代随机搜索

4. 实验设计：三条 ablation 决定 paper 成败

#	Ablation	回答的问题
A1	Direct $h(z_t, z_g)$ vs warm-start MPC	MPC 比 reactive policy 强吗? (否 → 我就是 GCBC)
A5	同 forward + CEM vs warm-start MPC	warm-start 比随机搜索快多少
A6	推理用 f (verify+refine) vs 不用 (direct h)	forward 在推理时真 work 吗

附加诊断 metric（直接对应三个病根）：

Metric	测什么
Action log-likelihood under training distribution	(P1) 是否解决
Spearman corr(latent L2, ground-truth steps-to-go)	(P2) 是否解决
Compounding error vs $H \in \{4, 8, 16, 32\}$	(P3) 是否解决

5. Benchmarks & Baselines

Benchmarks: Push-T（主），Two-Room, OGBench-Cube, CALVIN（stretch）

Policy 类 baseline（因为 inverse 本质是 hindsight GCBC）：

- GCBC on raw pixels
- GCBC on JEPA latent
- HILP / QRL

Planning 类 baseline:

- LeWM + CEM（同 codebase 直接对比）
- PLDM + CEM
- DINO-WM + CEM
- Random shooting + 同 f